

# AI Math

⊕ 구분

실습수업

## 지도학습

지도학습은 크게 1. 회귀 문제(Regression) 와 2. 분류 문제(Classification) 로 나눌 수 있다.

### 1. 회귀문제 (Regression Problem)

회귀문제를 해결하는 대표적인 알고리즘이 선형회귀이다.

선형회귀는 특정 수치를 예측하는 것이다. (미래 온도, 주가 등)

1. 데이터 X와 정답 Y가 주어지고, Y와 X의 관계를 가장 잘 나타내는 함수를 학습한다.
2. 예를 들어

$$y \text{ (집값)} = w * x \text{ (방 개수)} + b$$

이를 회귀모델(Regression Model)이라고 하며,  
x피쳐(feature, 입력 변수)  
y타겟(target, 예측값)  
a계수(coefficient, weight)  
b절편(intercept, bias)

함수가 데이터를 얼마나 잘 나타내는지 평가할 때 가장 많이 사용하는 것이

**MSE (Mean Squared Error, 평균제곱오차)** 이다.

$$\text{MSE} = (\text{실제 집값} - \text{예측 집값})^2 \text{의 평균}$$

1. 이렇게 모델이 얼마나 잘 또는 잘못 예측했는지를 수치로 나타내는 것을 **손실함수(Loss Function)** 라고 한다.

이 값을 최소화하도록 모델이 가중치 w와 편향값 b를 업데이트하는 것이 목표이다.

2. 그렇다면, 계산된 MSE를 가지고 가중치와 편향값을 얼마나 업데이트해야 할 지를 어떻게 알 수 있을까?
3. 최적화 알고리즘 (예시 **경사하강법(Gradient Descent)**) 이 그 방향과 크기를 알려준다.


예를 들어, 단순회귀를 가정하면

$$y \text{ (집값)} = w * x \text{ (방 개수)} + b$$

- 실제로는 다중회귀(방 개수, 화장실 개수, 학군지 등)가 일반적일 것이다.

$$y \text{ (집값)} = w1 * x1 \text{ (방 개수)} + w2 * x2 \text{ (평형)} + w3 * x3 \text{ (지하철 거리)} + b$$

하지만 이해를 위해 단순회귀라고 가정하자.



가중치 W 에 따른 MSE의 변화량이다.

단순회귀일 때 손실함수(MSE)는 일반적으로 볼록한 U자 형태를 보인다.

이때 U 그래프의 기울기가 최소가 되는 지점을 찾는 데 사용하는 것이 **미분**이다.

(미분은 순간 변화량 (우사인볼트) 라고 했다)

미분을 통해 기울기가 가장 작은 값을 찾는 다음 W와 B를 업데이트한다.

이것이 **경사하강법**이다.

경사하강법은 손실함수로부터 얻은 기울기를 가지고 W, B를 업데이트하는 최적화 알고리즘이다.

최적화를 통해 상황과 정답에 맞는 최적의 함수를 찾는 것이다.

## 2. 분류문제 (Classification Problem)

데이터를 미리 정해진 카테고리 중 하나로 예측하는 것이다.

예를들면 스팸메일 여부, 암 진단, 얼굴 인식 등이 있다.

분류문제를 해결하는 대표적인 알고리즘으로 로지스틱 회귀가 있다.

1. 데이터 X와 정답 Y가 주어지고, 입력 X가 어떤 클래스에 속하는지 예측하는 함수를 학습한다.
2. 예를 들어 이메일이 주어졌을 때, 이를 스팸메일(1) 또는 정상메일(0)로 분류하는 모델을 말한다.

$$y = f(ax+b)$$

$$y \text{ (스팸 여부)} = W(\text{가중치}) * X(\text{입력값}) + B(\text{편향})$$

3. 분류문제는 회귀문제와 다르게 출력값 Y가 단순한 수치가 아닌 **확률 형태**이다.

a. 회귀문제에서는 예측값이 연속적인 실수다.

- 집값 예측 → 3,120,000,000원
- 체온 예측 → 36.7°C

b. 반면, 분류문제에서는 예측이 “어떤 클래스에 속할 확률”이다.

- 고양이일 확률: 0.8
- 개일 확률: 0.2

이렇게 0~1 사이의 값 (확률 값)의 형태로 표현한다.

4. 그래서 분류문제에서는 예측값  $y$  을 확률 형태로 변환하기 위해 **시그모이드(Sigmoid)** 또는 **소프트맥스(Softmax)** 함수를 사용한다.

- **이항 분류**(예: 개 or 고양이)에서는 시그모이드 함수를 사용하여 출력이 0~1 사이 값을 갖게 하고,
- **다중 분류**(예: 고양이, 강아지, 토끼)에서는 소프트맥스 함수를 사용하여 각 클래스의 확률을 계산한 뒤, 가장 큰 확률을 선택한다.

---

## 손실함수 그리고 최적화 알고리즘

- 회귀문제에서는 예측값( $y^{\wedge}$ )와 실제값( $y$ )의 차이의 거리를 계산하기 때문에 MSE를 사용했지만
- 분류문제에서는 예측확률( $y^{\wedge}$ )과 실제정답(0 or 1)의 차이를 확률분포로 계산하기 위해 MSE가 아닌, 대신 **크로스 엔트로피(Cross Entropy Loss)**를 사용한다.

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

- 손실계산 이후 **GD(경사하강법)**, **Adam** 등과 같은 최적화 알고리즘으로  $W$ 와  $B$ 를 업데이트한다.

---

## 분류문제 모델의 평가 지표

분류문제에서 최적화를 마친 모델의 성능을 평가하는 대표적인 지표는 여러가지가 있지만 기본적으로 다음의 세가지만 살펴보자.

- **정확도 (Accuracy)**

- 올바르게 예측한 샘플 수 / 전체 샘플 수
- 예: 100개의 동전 중 4개가 가짜인데, 20개를 고른 것 중 2개만 정확히 골랐다면  
→ 정확도 2%
- 그러나 100개가 모두 진짜라면 정확도는 100%가 될 수 있음 → 샘플 데이터 분포의 영향 큼
- 직관적이고 해석이 쉽다 하지만, 데이터가 불균형할 경우 신뢰도가 낮아질 수 있다.

- **정밀도 (Precision)**

- 양성으로 예측된 것 중 실제로 양성인 비율
- 계산식:  $TP / (TP + FP)$
- 예: 100개의 동전 중 4개가 가짜인데, 20개를 고른 것 중 2개만 정확히 골랐다면  
→ 정밀도 10%  
 $2 / 20 = 10\%$  (정밀도 10%)  
모델이 가짜라고 판단한 것 중 10%만 진짜 가짜였다는 의미

- **재현율 (Recall)**

- 실제 양성 중 얼마나 많이 맞게 예측했는가
- 계산식:  $TP / (TP + FN)$
- 예: 100개의 동전 중 4개가 가짜인데, 20개를 고른 것 중 2개만 정확히 골랐다면  
→ 재현율  
 $2 / 4 = 50\%$  (재현율 50%)

그 외에 f1-score 그리고 AUC 등이 있다.(Area Under Curve)

- $f1\text{-score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

회귀문제의 평가성능 지표로 중 많이 사용하는 것으로 MSE 그리고  $R^2$ (결정계수) 등이 있다.

coefficient of determination은 모델이 데이터를 얼마나 잘 설명하고 있는가를 계산하는데

수식은 아래와 같아.

자세한 계산식은 생략하지만, 결과값이 1에 가까우면 아 이 모델은 데이터를 잘 반영하고 있구나 라고 판단하고 0이면 땡 탈락이다.

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

지금까지 머신러닝에서 **지도학습**에 대해 살펴보았다.

머신러닝의 학습 방법으로는

1. 지도학습
2. 비지도학습
3. 강화학습
4. 딥러닝 으로 크게 나눌 수 있다고 했으며,

오늘, 지도학습에 대해서 살펴 보았고 오늘 실습에서 볼 내용이 바로 이 내용들이다.

1. 회귀문제 (Regression Problem) - (대표적인 알고리즘 : 선형회귀 (Linear Regression))
2. 분류문제 (Classification Problem) - (대표적인 알고리즘 : 로지스틱 회귀 (Logistic Regression))